



# DQN의 2048 게임 적용에 대한 한계 분석 및 개선 가능성 탐색

강화시스터즈 세션 01

장예원, 최상아, 한사랑

# 목차

- I. 서론
- II. 관련 연구
- III. 연구 방법
- IV. DQN 성능 개선 요인
- V. 결론





# I. 서론

## 1. 연구 배경

- Q-learning: 상태-행동의 누적 보상(Q-value) 기반 학습
- 전통적 Q-learning의 한계: 작은 상태 공간에서만 사용 가능
- 21세기 이후: 이미지·동영상 등 고차원 비정형 데이터를 딥러닝으로 처리 → 강화학습 확산

## 2. 연구 필요성

- 고차원 데이터를 처리하기 위해 Q값 근사 + 경험 저장 가능한 신경망 기반 Q-learning(DQN) 필요

## 3. 연구 목적

- 2048 게임을 강화학습으로 해결
- 4x4 보드 상태공간에서 DQN 알고리즘의 성능을 실험적으로 검증

# I. 서론

## 4. 연구 목표

- 퍼즐 게임 2048 환경에 심층 Q-네트워크(DQN) 적용
- 다양한 성능 개선 요인 실험적 검증
  - Double DQN
  - Dueling DQN
  - Prioritized Experience Replay (PER)
  - $\epsilon$ -탐욕 정책 수렴 속도
  - 보상 설계 (Reward Shaping)

## 5. 최종 목표

- 여러 방법론을 비교·분석하여 2048에서 가장 안정적이고 효율적인 DQN 구조 제안



# II. 관련 연구

## 1. 사례 개요

- 분석 대상: YangRui (2015)의 2048 DQN 공개 프로젝트(2048\_env)
- 목적: 단순 고득점 달성 → DQN 한계 극복 & 안정적 학습 구조 탐구
- 방법: CNN 기반 상태 표현 + 알고리즘 개선 기법 종합 적용

## 2. 문제 접근 방식

| CNN 상태 표현                                 | 보상 설계 (Reward Shaping)                            | 알고리즘 개선                                                                                                                 |
|-------------------------------------------|---------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|
| 4x4 보드를 CNN 입력으로 사용<br>→ 타일 위치·값 특징 자동 추출 | 단순 점수 보상 → 불안정<br>log2(1+r) 보상 적용 → 변동 억제, 학습 안정화 | PER: 예측 실패 경험 우선 학습 → 효율 향상<br>Double DQN: Q-value 과대평가 완화<br>Target Network soft update,<br>Gradient clipping → 안정성 확보 |

## II. 관련 연구

### 3. 결과 분석

- 학습 성능
  - 40,000 에피소드 학습 → reward/steps 꾸준히 상승
  - Loss 급격히 감소 후 안정적 유지
- 최고 타일
  - 장기간 512 타일 → 후반부 1024 달성 ('퀀텀 점프')
- 평가 성능
  - 평균 점수: 약 5,100
  - 최대 점수: 11,500

### 4. 종합 및 시사점

| 성공적인 DQN 적용                                              | 다양한 기법의 조합                                                         |
|----------------------------------------------------------|--------------------------------------------------------------------|
| YangRui (2015)의 사례는 2048 게임에 DQN을 성공적으로 적용한 대표적인 연구로 평가됨 | 단일 기법보다는 CNN, PER, Double DQN, 보상 설계 등 여러 개선 기법의 조합이 성능 향상에 크게 기여함 |
| 안정성과 성능 동시 확보                                            | 확장 가능성 제시                                                          |
| 이러한 통합적 접근 방식은 학습 안정성과 게임 성능을 동시에 확보하는 데 핵심적인 역할을 함      | 이는 2048과 같은 복잡한 환경에도 강화 학습 알고리즘의 성공적인 확장이 가능함을 시사함                 |

# III. 연구 방법

## 1. 환경 (Environment)

- 직접 구현한 Gym 스타일 2048 환경
  - OpenAI Gym 규약 준수: reset, step, render 지원
  - 다양한 DQN 알고리즘 비교 가능하도록 설계

## 2. 상태 표현 (State Representation)

- 4x4 보드를 원-핫 인코딩 방식으로 변환
- $\{2, 4, \dots, 2^{16}\} \rightarrow 16$ 개 채널에 투영
- 결과: 4x4x16 텐서 형태 입력
- **CNN**이 고차원 상태를 효과적으로 처리하도록 설계



# III. 연구 방법

## 3. 행동 정의 (Action Space)


- 상/하/좌/우 4가지 행동
- **합법적 이동**: 타일 병합 + 무작위 신규 타일 추가 (90%: 2, 10%: 4)
- **불법 이동**: 보드 변화 없음 → 보상 0, 새로운 타일 미생성
- 스텝 수는 정상적으로 증가 (불필요 시도 누적 방지)
- Action Mask 제공 → 무효 행동 차단

## 4. 보상 함수 설계 (Reward Shaping)

- **병합 보상**: 이동 시 병합된 타일 합을 로그 스케일로 변환
- **빈 칸 보상**: 현재 보드의 빈 칸 개수를 로그 스케일로 보상에 반영
- 단조성(monotonicity), 평탄성(smoothness) 등 휴리스틱은 제외
- **목적**: 단순한 과적합 방지 + 학습 안정성 강화

# III. 연구 방법 I CNN

입력 이미지



|   |                   |                      |
|---|-------------------|----------------------|
| 2 | [1, 0, 0, ..., 0] | 2에 대응하는 채널이 1, 나머지 0 |
| 4 | [0, 1, 0, ..., 0] | 4에 대응하는 채널이 1, 나머지 0 |
| 8 | [0, 0, 1, ..., 0] | 8에 대응하는 채널이 1, 나머지 0 |

|            |                     |
|------------|---------------------|
| CNN        | conv1, conv2, conv3 |
| 각 계층       | 128층                |
| 커널 크기      | 3x3                 |
| 활성화 함수     | ReLU                |
| FCL        | 총 2개                |
| 은닉층 노드수    | 528개                |
| 출력층 output | Q 값 4개 (상/하/좌/우)    |
| 가중치 초기화    | He                  |

# III. 연구 방법 | Dueling & Double DQN


마지막 출력층에서

$$Q(s, a) = V(s) + A(s, a) - \frac{1}{|\mathcal{A}|} \sum_{a'} A(s, a'),$$

**Value stream** ( $V(s)$ )    단일 스칼라 값으로 추정

**Advantage stream** ( $A(s, a)$ )    행동의 상대적 우위를 추정

.....



# III. 연구 방법 | Replay Buffer

Replay Buffer

균등 선택

**Prioritized Experience Replay**

우선 순위(TD-Error) 기반 선택

샘플링 편향 보정



# III. 연구 방법 | 학습 조건

|        |             |
|--------|-------------|
| 학습 반복  | 3,000회      |
| 최적화 기법 | Adam        |
| 평가/로딩  | 10 episodes |


## 하이퍼파라미터

|                                    |             |
|------------------------------------|-------------|
| Replay Buffer                      | 100,000     |
| 배치 사이즈                             | 64          |
| $\gamma$                           | 0.99        |
| Learning Rate                      | 0.0001      |
| $\epsilon_{start}, \epsilon_{end}$ | 0.9, 0.01   |
| Decay                              | 30,000      |
| 타겟 네트워크 동기화                        | 1,000 steps |


# III. 연구 방법 | 평가 지표



최고 타일



평균 점수



에피소드 길이

# III. 연구 방법 | 평가 방법

Greedy Policy

+

주기적 평가

기본 DQN


Double DQN

Dueling DQN

우선순위 경험 재생(Prioritized Replay, PER)

액션 마스킹 기법

보상, 점수, 최고 타일, 스텝 수, 손실 값



## IV. DQN 성능 개선 요인 (1)

|                                                |         |        |       |       |
|------------------------------------------------|---------|--------|-------|-------|
| <del>Double DQN</del>   <del>Dueling DQN</del> | 2,241.0 | 7,048  | 198.4 | 512   |
| Double DQN   <del>Dueling DQN</del>            | 2,270.2 | 6,440  | 202.9 | 512   |
| <del>Double DQN</del>   Dueling DQN            | 6,007.2 | 15,776 | 426.2 | 1,024 |
| Double DQN   Dueling DQN                       | 7,403.1 | 17,456 | 506.9 | 1,024 |

실험 4 > 실험 3 > 실험 2 > 실험 1

실험1 v.s. 실험2

제한적인 성능 향상

실험1 v.s. 실험3

2241.0 ▶ 6007.2 (2.7배), 198.4 ▶ 426.2로 (2배), 1024 안정적 성취

실험3 v.s. 실험4


6007.2 ▶ 7403.1(23%), 426.2 ▶ 506.9, 두 기법의 시너지

실험

## IV. DQN 성능 개선 요인 (2)

### Replay Buffer

핵심 컨셉: 무작위 균등 샘플링



한계점:

- 덜 중요한 경험과 중요한 경험을 동일하게 취급
- 시간적 상관관계 문제 해결, 그러나 학습 효율이 not 최적


실험 결과:

PER의 압도적인 성능 우위

"학습 효율의 차이가 최종 성능의 차이를 만든다."

### Prioritized Experience Replay (PER)

핵심 컨셉: 중요도(TD-Error) 기반 샘플링



장점:

- "예측과 실제의 차이가 큰" 놀라운 경험 집중 학습
- 학습 효율을 극대화하여 더 빠르고 높은 성능 달성

| 지표          | Replay Buffer | Prioritized Replay |
|-------------|---------------|--------------------|
| 평균 점수       | 5831.4        | 8224.6 (▲ 41%)     |
| 평균 최고 타일    | 415.4         | 572.2 (▲ 38%)      |
| 1024 타일 점유율 | 1x            | ~ 7x               |



## IV. DQN 성능 개선 요인 (3)

### 탐험 (Exploration)

- 개념: 새로운 가능성을 찾기 위한 무작위 행동
- 목표: 더 나은 미지의 보상을 발견 (장기적 이득)

VS

### 활용 (Exploitation)

- 개념: 현재까지의 최선책을 따르는 결정론적 행동
- 목표: 이미 알고 있는 최대의 보상을 획득 (단기적 이득)

-> Epsilon( $\epsilon$ )은 '탐험'을 할 확률,

-> Epsilon Decay는 학습이 진행됨에 따라 점차 '활용'의 비중을 높이는 전략


### 실험: 세 가지 Epsilon Decay Rate 비교

| 지표          | A: 느린 수렴            | B: 빠른 수렴                | C: 기본 수렴                      |
|-------------|---------------------|-------------------------|-------------------------------|
| decay 값     | 50000               | 15000                   | 30000 (기본)                    |
| e start/end | 1.0 / 0.05          | 0.8 / 0.01              | 0.8 / 0.005                   |
| 그래프 양상      | 학습 속도 더딤,<br>성능 불안정 | 주기 수렴,<br>더 좋은 전략 발견 실패 | 🏆 꾸준한 성능 향상,<br>안정적인 최고 성능 달성 |

**실험 결과:**  
기본  $\epsilon$  설정이 가장  
효과적인 탐험 전략임을 확인.

# IV. DQN 성능 개선 요인 (4)

## 실험: 세가지 단계별 보상 설계



## 실험 결과:

게임의 핵심 전략(타일 병합 + 공간 확보)를

직접적으로 반영한 보상 함수가 가장 효과적임을 실험적으로 입증함.

# V. 결론

## A. 구조 (Architecture)

키워드: **Double DQN / Dueling DQN**

효과:

- ✓ Q-value 과대평가 완화
- ✓ 학습 안정성 및 성능 대폭 향상

## B. 경험 활용 (Memory)

키워드: **Prioritized Experience Replay**

효과:

- ✓ 중요 경험 데이터 집중 학습
- ✓ 학습 효율성 및 수렴 속도 개선

## C. 탐험 전략 (Exploration)

키워드: **Epsilon Decay Rate**

효과:

- ✓ 탐험-활용간 균형 확보
- ✓ 안정적인 최고 성능 달성

## D. 보상 설계 (Reward)

키워드: **Reward Shaping**

효과:

- ✓ 단기적 보상과 장기적 생존 동시 고려
- ✓ 고차원적 전략 학습 유도





# Thank you!